

Agent 开发周报 260520

刘德辰

2026 年 5 月 20 日

1 流式开场与历史上下文（轻量）

背景：首屏仍可能久等 router/worker；报告 API 阶段文案易与正文重复；多轮时 opening 未进上下文会导致 worker 重复开场。

本周：调整顺序为主——开场前移到 router 前，再恢复生成式 opening，并把 opening 历史传给 worker，改善首屏反馈、减少重复开场；报告 API 去掉多余 stage text；probe 阶段与生产可见顺序一致。属体验层改动，不动 router 选路逻辑。

相关提交（日期）：

- f721a32、93d8d49、9808bf8、8f75558（2026-05-14~18）

2 Router 主链路减负与排障

背景：流式探针接入后，瓶颈主要在规则匹配 → 场景匹配 → router → worker 整条链路；router prompt 和工具 schema 偏长，既费 token 也难定位慢在哪。

亮点：probe 模式下 **command router**（模型输出紧凑 JSON 指令，不走 function-calling tools）相较原 router，在现有环境下 路由阶段平均快约 12s，耗时约降 30%——本周收益最大的一项。

本周：在不换生产 router 模型/协议的前提下，复用规则匹配的 query embedding、压缩 router skill 和 tool schema，并修正 buildRouterTools([])（undefined 全量、[] 无工具）。新增 pipeline probe 阶段；command router 目前仅 probe 启用，输出无效或工具不在 allow-list 时回退 function-calling，生产 /chat/stream 仍走原路径。

要点：

- 少一次重复 embedding；prompt/工具描述更短，报告/咨询/专家/规则边界保留。
- probe 可看 rule_match_*、router_call_*、command_router_*、worker_started、main_first_delta 等。

相关提交（日期）：

- 2cc05db、93d8d49、00cb5d7、49689dc（2026-05-17~18）

3 报告生成：工具轮次用尽时的收尾

背景：多轮报告/长历史下，worker 易把轮次耗在继续查数，触发超限后用户拿不到基于已有结果的答复。

本周: 达上限前, 若有工具结果则强制收尾生成 (禁止再调工具); 数据不足则说明缺什么。probe 增加 `max_iterations_finalize_*`; 收尾失败仍保留原超限错误。

相关提交 (日期):

- 5d871a0 (2026-05-18)

4 单位/驾驶员趋势对比数据

背景: 报告已走 MCP, 但同比/环比/同单位/同线路对比仍不全, 趋势解释偏弱。

本周: 消费单位 key risk trends; 驾驶员侧接入 `quotaScoreTrend`、`driverRiskScore` 并写入报告 source; `report-source-contract` 增加趋势字段校验。驾驶员趋势部分为工作区改动, 待提交。

相关提交 (日期):

- 500b99b (单位趋势, 2026-05-18)

5 五类报告召回回归

背景: router 调整后需固定 R+/R- 样例, 防止召回率或误触发倒退。

本周: 补齐车辆/驾驶员/线路/单位/事故 5/14 manual; 新增 `run_recall_tests.py` (Playwright + 拦截 final SSE, 以 `metadata.tool` 判定)。线路 R+ 5/5、R- 全拒; 车辆/驾驶员/事故 R+ 4/5、R- 5/5、误触发 0。待修: 车辆多轮 Q2 误走专家、驾驶员英文 briefing 误走咨询、事故别名未稳定进报告管线; 单位 E1/E2 命中、E3/E5 正确拒绝, 统计待补全。

材料: `agent/docs/manual/*20260514.md`、`run_recall_tests.py` (工作区, 待提交)

6 MCP 工具文档审查 (20260515)

背景: 工具 description 影响选工具与填参; 文档存在序号重复、列表与正文不一致、字段易混等问题。

本周: 审查 20260424 (19 接口) 与 20260515 (新增 3 接口), 输出 `mcp-aisecurity-tools-description-review-` 含字段替换候选; 重点理清趋势 vs 对比、相近字段边界及新增统计接口的窗口/分页说明。

材料: 文档审查 (工作区, 待提交)

7 Retrieval: PDF OCR fallback

背景: 扫描 PDF 无文本层时原先直接 `PDF_OCR_REQUIRED`, 测试环境难以端到端验证。

本周: 增加 OCR 配置与 `parseDocumentWithOcr` fallback; 普通文档仍原路径, OCR 默认关。Docker 可通过 `host.docker.internal` 联调宿主机 OCR。

材料: retrieval 改动 (工作区, 待提交)

8 下周计划

1. 解决工单问题

2. 验证 router 压缩与 command router 的召回/回退率，评估是否值得在生产推广（已见 probe 路由约快 12s、耗时降约 30%）。
3. MCP 修改版让交信投更新并确认效果。
4. 测试环境启用 OCR，用扫描 PDF 跑通预览 → 入库 → 检索 → 问答。
5. 规则回复管线完成全部验证和闭环。

相关提交（日期）：本节为下周计划，无对应本周单一提交。