

Agent 开发周报 260527

刘德辰

2026 年 5 月 27 日

1 模型服务兼容与 Qwen reasoning 流

背景：测试/本地模型网关不一定需要 OPENAI_API_KEY，但原链路会在本地提前拦截；Qwen reasoning 模型的流式响应会返回 reasoning / reasoning_content，需要兼容解析，同时避免 reasoning 配置影响工具调用稳定性。

本周：把模型调用、embedding、规则/场景匹配等链路的 OPENAI_API_KEY 改为可选；请求头仅在 key 存在时附加 Authorization，使无鉴权网关和内网兼容 OpenAI 接口可直接接入。新增 enable_thinking / chat_template_kwargs.enable_thinking 适配，并在 SSE 解析中捕获 reasoning delta；专家 worker 是否启用 thinking 改由 OPENAI_EXPERT_THINKING_ENABLED 控制，默认不强开，减少与 function/tool calling 的兼容风险。

相关提交（日期）：

- 35df8f8、e5afe60、4f1d170（2026-05-22~27）

2 流式 probe 与 command/function router 对比

背景：上周已看到 command router 在 probe 中有明显耗时收益，但还缺少可复现、可对照的前端比较视图；直接并发比较也会受上游并发波动影响，难判断单次差异。

本周：pipeline-stream-probe 增加 routerMode 参数，支持 command router 与原 function-calling router 显式切换；前端研究页新增 Compare routers 模式，按 command → function 的顺序执行，并记录各自 first byte、first event、first text、elapsed、事件序列和输出内容。补充 Markdown 快照复制，便于把 probe 结果沉淀到文档；布局改成全宽，避免长事件/长输出挤压。

要点：

- Compare 模式不再只看单条链路，而是同一 prompt 下顺序跑两条 router 路径。
- probe 事件继续覆盖 opening、router、worker、tool、final 等阶段，便于定位慢点。
- 前端增加会话 ID 搜索过滤，方便按测试 session 回查结果。

相关提交（日期）：

- a4cac4a、ac965dd、b4d74a1、0a7684f、82e761f、13f6847（2026-05-23~27）

3 PoingCode 工单处理

背景：本周修复主要来自 PoingCode 工单，集中在专家问答中途失败、风险分解释错误、报告数据缺项和报告时间口径不一致等问题。

本周：处理专家问答工具轮次耗尽后直接报错的问题，改为基于已查到的数据给出回答，数据不足时明确说明缺少哪些字段；补充风险分解释约束，避免把风险分当成“越高越好”的安全分。驾驶员报告接入同比、环比、同单位、同线路等趋势对比数据，并写入报告来源；线路报告统一日期格式，将统计窗口修正为 7 天，避免单日/周维度混用。

相关提交（日期）：

- 4075db2、a90ef9e、98ead4a、fc14371、ff72543（2026-05-22~27）

4 Retrieval: PDF OCR fallback 与独立 OCR 服务

背景：扫描 PDF 没有文本层时会直接失败，知识库预览、入库、检索无法端到端验证；OCR 作为重依赖能力，需要独立部署、独立限流和清晰错误码。

本周：新增 agent/retrieval/ocr-service，提供 FastAPI /ocr/parse，支持 PDF/图片解析、文件大小限制、页码范围、超时、错误码和健康检查；OCR 引擎基于 PaddleOCR，采用 worker pool + 子进程隔离，超时或 worker 异常时可替换进程。Retrieval 侧新增 OCR_ENABLED、OCR_BASE_URL、OCR_TIMEOUT_MS、OCR_LANGUAGE，PDF 普通解析失败或文本层过短时调用 parseDocumentWithOcr fallback，并在 preview warnings 中标记 PDF_OCR_APPLIED / PDF_TEXT_PARSE_FAILED。Docker compose 增加 host.docker.internal 映射，便于容器内 KB 服务联调宿主机 OCR。

相关提交（日期）：

- 98aea3a（2026-05-26）

5 报告召回与车牌容错自动化资产

背景：router 和报告管线连续调整后，需要把手工样例固化成可重复执行的回归资产，尤其是报告应召回/不应召回、车牌缺“粤 A”前缀等容错场景。

本周：提交报告召回测试资产：run_recall_tests.py 覆盖单位、线路、驾驶员、事故的单轮/多轮场景，并通过 final SSE 中的 metadata.tool 判断命中；新增 recall-test-runner.mjs 支持 API 级执行线路/车辆报告召回 fixtures，输出 JSON 和 Markdown；新增 plate-tolerance-test.mjs 和车牌容错 fixture，验证缺省粤 A 车牌是否仍能路由到车辆报告、并区分“路由命中”和“数据命中”。

材料：

- agent/docs/manual/run_recall_tests.py
- agent/scripts/recall-test-runner.mjs
- agent/scripts/plate-tolerance-test.mjs
- agent/fixtures/*recall*.json
- agent/fixtures/vehicle-plate-tolerance-cases-20260421.json

相关提交（日期）：

- 7a821c0（2026-05-26）

6 MCP 文档与交付材料整理

背景：MCP 工具 description、样例和接口文档会直接影响 router 选工具和模型填参；上周审查结果、5/14 manual 与周报文档仍有一批材料未提交。

本周：补齐 20260514 各类报告召回 manual；完成并提交 description 第一版 review，重点审核工具说明、字段口径和入参描述中容易导致“数据查不到”的问题，后续更新后有望改善部分查询失败场景。已准备第二版待办，但需等第一版更新落地并验证效果后，再继续细化第二版修改内容。同步提交 260513、260520 周报和算力建议材料，形成文档包。

相关提交（日期）：

- 3af522c（2026-05-25）

7 下周计划

1. 继续解决工单问题，优先处理会影响生产体验的专家问答和报告生成问题。
2. 用 Compare routers 跑固定样例，统计 command router 的召回、回退、耗时和失败率，判断是否具备上线条件。
3. 部署新版 retrieval 和 OCR 服务，上传新的文档，完成扫描 PDF 的预览、入库、检索、问答闭环。
4. 跟进 MCP 文档修改版交付与字段口径确认，重点核对趋势、对比、风险分语义。

相关提交（日期）：本节为下周计划，无对应本周单一提交。